



深度学习与典型神经网络

Deep Learning and Classical Neural Networks



授课对象：计算机科学与技术专业 二年级

课程名称：人工智能（专业必修）

节选内容：第六章 机器学习

课程学分：3学分






前情知识回顾：神经网络


输入层

输出层




单层神经网络/感知机 (Perceptron)

无法解决XOR (异或) 这样简单分类任务




输入层

输出层



多层神经网络/多层感知机 (MLP)

可以解决复杂分类任务



随着层数的增加，神经网络的学习能力越来越强，能完成更多更难的任务



问题引入

卷积神经网络

循环神经网络




长短期记忆网络

可解释性




前情知识回顾：神经网络

深度学习

随着层数的增加，神经网络的学习能力越来越强，能完成更多更难的任务




更深，
更复杂.....






前情知识回顾：神经网络




“神经元”

$$y = \sigma(z) \\ = \sigma(W * x + b)$$




Sigmoid Function +

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$






前情知识回顾：神经网络



神经网络参数：“神经元”中的权重(weights) W 和 偏置(biases) b




前情知识回顾：神经网络



Sigmoid
Function


$$\sigma(z) = \frac{1}{1 + e^{-z}}$$





前情知识回顾：神经网络


Try it!





前情知识回顾：神经网络


函数视角



$$\sigma\left(\underbrace{\begin{bmatrix} 1 & -2 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix}}_{\begin{bmatrix} 4 \\ -2 \end{bmatrix}}\right) = \begin{bmatrix} 0.98 \\ 0.12 \end{bmatrix}$$



前情知识回顾：神经网络




$$\sigma(W^1 x + b^1) \rightarrow \sigma(W^2 a^1 + b^2) \rightarrow \dots \rightarrow \sigma(W^L a^{L-1} + b^L)$$

The diagram shows the mathematical representation of the forward pass through the hidden layers. The input vector x is multiplied by the weight matrix W^1 and the bias vector b^1 is added, followed by the sigmoid activation function σ . The result is the hidden layer output a^1 . This process repeats for subsequent layers, with a^1 being multiplied by W^2 and b^2 added, followed by σ to produce a^2 , and so on, until the final hidden layer output a^{L-1} is multiplied by W^L and b^L added, followed by σ to produce the final output y .



前情知识回顾：神经网络




$$y = f(x)$$

使用**并行计算**技术来加速矩阵操作

$$= \sigma(W^L \dots \sigma(W^2 \sigma(W^1 x + b^1) + b^2) \dots + b^L)$$



前情知识回顾：神经网络



相当于函数功能

输入一个向量，输出另一个向量


$$f\left(\begin{bmatrix} 1 \\ -1 \end{bmatrix}\right) = \begin{bmatrix} 0.62 \\ 0.83 \end{bmatrix} \quad f\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}\right) = \begin{bmatrix} 0.51 \\ 0.85 \end{bmatrix}$$

网络结构相当于定义了函数空间



前情知识回顾：神经网络

功能视角



从功能角度讲，神经网络就是多层的**特征提取**加上**线性分类**



深度学习概念与分类

“深度” = 非常多隐藏层

8 layers

19 layers

22 layers

误差率: 16.4%

7.3%

6.7%

深度学习只是堆叠层数吗?

只堆叠层数会有什么问题?

回顾上节: 随着层数增加, 参数更新梯度呈现指数衰减, 低层基本上接受不到有效的训练信号, 即**梯度消失问题!**

AlexNet (2012)

VGG (2014)

GoogLeNet (2014)



问题引入

卷积神经网络

循环神经网络

长短期记忆网络

可解释性

深度学习概念与分类

152 layers

22 layers

19 layers

8 layers

误差率: 16.4%

7.3%

6.7%

3.57%

特殊
结构

深度学习不只是
堆叠层数,
还需**特殊结构**

AlexNet (2012)

VGG (2014)

GoogleNet (2014)


Residual Net (2015)

广州塔(2009)



深度学习概念与分类


- 视觉数据: CNN (卷积神经网络), ResNet, DenseNet,
- 文本数据: RNN, LSTM, Transformer, Bert, ChatGPT...
- 其他数据: AlphaFold (2024年诺贝尔化学奖: 蛋白质结构预测) ...



深度学习发展历史


Bengio在自然语言处理与注意力机制、**生成式模型**、序列概率模型上有贡献

Hinton是**反向传播算法**和玻尔兹曼机的提出者，也是**2024年诺贝尔物理学奖获得者**



历史上的AI寒冬期

- 20世纪80~90年代AI寒冬中，许多研究者和资金转向其他领域



Yoshua Bengio



Geoffrey Hinton



Yann LeCun

2018年图灵奖获得者

- 他们持之以恒地研究神经网络，取得诸多开创性成就

LeCun独立发现并改进了**反向传播算法**，提出**卷积神经网络 (CNN)**

卷积神经网络的视觉机理

• 任务：



猫 or 狗？

卷积神经网络的视觉机理


有什么问题？

• 思路：



猫 or 狗？

忽略图片结构特性！



多层感知机
(MLP)就是一个
分类器！

模型参数量庞大！

卷积神经网络

人类视觉机理的启发

人观测图片的特点：

人不必看完整张图片来识别




鸟

人类视觉机理的启发

人观测图片的特点：① 局部特征影响大

人不必看完整张图片来识别



“鸟嘴” 检测器

一些局部特征要比
整张图片小得多

人类视觉机理的启发

人观测图片的特点： ① 局部特征影响大 ② 重要位置常变化

相同特征会出现在不同区域




人类视觉机理的启发

人观测图片的特点： ① 局部特征影响大 ② 重要位置常变化 ③ 采样压缩也没差

对图片进行下采样不会改变识别对象信息




下采样压缩





➡ 通过下采样可以压缩图片，使用更少的参数来处理

基于视觉机理的卷积神经网络架构设计

如何根据人类视觉特点设计网络？① 局部特征影响大





多层感知机
MLP



CNN

基于视觉机理的卷积神经网络架构设计

如何根据人类视觉特点设计网络？② 重要位置常变化



卷积核：可移动的权重矩阵

卷积核运算

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

6 x 6

1	-1	-1
-1	1	-1
-1	-1	1

卷积核 1

-1	1	-1
-1	1	-1
-1	1	-1

卷积核 2

.....


需要学习的网络参数

Property 1


局部特征影响大

每个卷积核可以
识别区域特征(3 x 3)


卷积核运算




(a) $0 \times 1 + 1 \times 2 + 2 \times 4 + 3 \times 5 = 25$



(b) $0 \times 2 + 1 \times 3 + 2 \times 5 + 3 \times 6 = 31$



(c) $0 \times 4 + 1 \times 5 + 2 \times 7 + 3 \times 8 = 43$



(d) $0 \times 5 + 1 \times 6 + 2 \times 8 + 3 \times 9 = 49$

卷积核运算


stride(步长)=1

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

6 x 6

1	-1	-1
-1	1	-1
-1	-1	1

卷积核 1



卷积核运算


stride(步长)=2

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

6 x 6

1	-1	-1
-1	1	-1
-1	-1	1

卷积核 1



卷积核运算

stride=1

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

6 x 6 image

1	-1	-1
-1	1	-1
-1	-1	1

卷积核 1

3	-1	-3	-1
-3	1	0	-3
-3	-3	0	1
3	-2	-2	-1

特征图

Property 2

特征位置可变化

不同区域的
相似特征可识别

卷积核运算

计算下不同步长下的特征图




步长=1 and 2

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

6 x 6


影响特征图的维度还有哪些因素?



步长=1: 4 x 4

-1	1	-1
-1	1	-1
-1	1	-1

卷积核 2




步长=2: 2 x 2

特征图的维度

假设图片为（高度 n_h x 宽度 n_w ）
卷积核为（ $f \times f$ ），步长为 $s = 1$

特征图为（高度 h x 宽度 w ）




特征图的维度

[分组讨论：维度公式]

假设图片为（高度 n_h x 宽度 n_w ）
卷积核为（ $f \times f$ ），步长为 $s = 2, \dots$

特征图为（高度 h x 宽度 w ）



特征图的维度

[分组讨论：维度公式]

假设图片为（高度 n_h ×宽度 n_w ）
卷积核为（ $f \times f$ ），步长为 $s = 2, \dots$

特征图维度：

$$\text{高度 } h = \left\lfloor \frac{n_h - f}{s} + 1 \right\rfloor$$

$$\text{宽度 } w = \left\lfloor \frac{n_w - f}{s} + 1 \right\rfloor$$

Input

4	9	2	5	8	3
2	4	5	4	5	2
5	6	5	4	7	8
5	7	7	9	2	1
5	8	5	3	8	4

Dimension: 6 x 6

*

Filter

1	0	-1
1	0	-1
1	0	-1

Parameters:

Size: $f = 3$

Stride: $s = 2$

Padding: $p = 0$

=

Result

2	1

1 = $2 \times 1 + 5 \times 0 + 3 \times (-1) +$
 $2 \times 1 + 4 \times 0 + 3 \times (-1) +$
 $5 \times 1 + 4 \times 0 + 2 \times (-1)$

特征图的维度

假设图片为（高度 n_h ×宽度 n_w ）
卷积核为（ $f \times f$ ），步长为 s ，填充宽度为 p

$p = 1$

Input							
0	0	0	0	0	0	0	0
0	4	9	2	5	8	3	0
0	5	6	2	4	0	3	0
0	2	4	5	4	5	2	0
0	5	6	5	4	7	8	0
0	5	7	7	9	2	1	0
0	5	8	5	3	8	4	0
0	0	0	0	0	0	0	0

Dimension: 6 x 6

*

1	0	-1
1	0	-1
1	0	-1

Parameters:

Size: $f = 3$

Stride: $s = 2$

Padding: $p = 1$

=

-15		

$$\begin{aligned}
 &= 0 \cdot 1 + 0 \cdot 0 + 0 \cdot (-1) + \\
 &\quad 0 \cdot 1 + 4 \cdot 0 + 9 \cdot (-1) + \\
 &\quad 0 \cdot 1 + 9 \cdot 0 + 6 \cdot (-1) \\
 &= -15
 \end{aligned}$$

特征图维度:

$$\text{高度 } h = \left\lfloor \frac{n_h - f + 2p}{s} + 1 \right\rfloor$$

$$\text{宽度 } w = \left\lfloor \frac{n_w - f + 2p}{s} + 1 \right\rfloor$$


特征图的维度

图片为（高度 n_h × 宽度 n_w × 深度 n_c ）
卷积核为（ $f \times f \times n_c$ ），步长为 s ，填充为 p

特征图维度：


$$\text{高度 } h = \left\lfloor \frac{n_h - f + 2p}{s} + 1 \right\rfloor$$

$$\text{宽度 } w = \left\lfloor \frac{n_w - f + 2p}{s} + 1 \right\rfloor$$



特征图的维度

图片为（高度 n_h ×宽度 n_w ×深度 n_c ）
 K 个卷积核为（ $f \times f \times n_c$ ），步长为 s ，填充为 p



特征图维度:


$$\text{高度 } h = \left\lfloor \frac{n_h - f + 2p}{s} + 1 \right\rfloor$$

$$\text{宽度 } w = \left\lfloor \frac{n_w - f + 2p}{s} + 1 \right\rfloor$$


$$\text{深度 } k = K$$

特征图的维度

【练习】算一算




一个完整的卷积层



卷积神经网络

如何根据人类视觉特点设计网络？③ 采样压缩也没差



卷积

3	-1	-3	-1
-3	1	0	-3
-3	-3	0	1
3	-2	-2	-1

采样

3	0
3	1

卷积神经网络

Max Pooling (最大池化)

1	-1	-1
-1	1	-1
-1	-1	1

卷积核 1

-1	1	-1
-1	1	-1
-1	1	-1

卷积核 2

3	-1	-3	-1
-3	1	0	-3
-3	-3	0	1
3	-2	-2	-1


-1	-1	-1	-1
-1	-1	-2	1
-1	-1	-2	1
-1	0	-4	3

卷积神经网络


Max Pooling (最大池化)

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0


6 x 6 image



Conv

Max
Pooling


更少的特征信息




2 x 2 image

池化的好处是什么?

卷积神经网络模型架构



卷积神经网络模型架构



Convolution

Max Pooling

新特征图

Convolution

Max Pooling

新特征图

展开

卷积神经网络(CNN) vs 人工神经网络(ANN)

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

图像

1	-1	-1
-1	1	-1
-1	-1	1

-1	1	-1
-1	1	-1
-1	1	-1

卷积


-1	-1	-1	-1
-1	-1	-2	1
-1	-1	-2	1
-1	0	-4	3

(CNN)
v.s.
(ANN)

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

图像


展开



卷积的好处?


以ANN视角看CNN

CNN




以ANN视角看CNN

CNN



6 x 6 image

减少更多参数!



ANN

共享权重

卷积神经网络应用


图像处理领域



高速公路测速



机器人视觉



医学图像分析



卷积神经网络应用



循环神经网络

为什么使用Recurrent Neural Network?

在订票系统中设置几个槽位 (Slot)，希望算法能够将关键词 'Guangzhou' 放入目的地 (Destination) 槽位，将 May 和 31th 放入到达时间 (Time of Arrival) 槽位。




循环神经网络

使用全连接神经网络解决？

输入: 一个单词
(每个单词用一个向量表示)

Guangzhou



循环神经网络

如何用向量表示单词？

One-hot Encoding

词典 = {apple, bag, cat, dog, elephant}

向量和词典大小相同

每个维度对应一个单词

对应维度的单词为1，其他位置为0

apple = [1 0 0 0 0]

bag = [0 1 0 0 0]

cat = [0 0 1 0 0]

dog = [0 0 0 1 0]


elephant = [0 0 0 0 1]

循环神经网络

输入: 一个单词
(每个单词用一个向量表示)

输出:
分类标签的概率分布

使用全连接神经网络解决?



循环神经网络

arrive Guangzhou on May 31th

other dest other time time

存在什么问题?

leave Guangzhou on May 31th


place of departure

神经网络需要记忆功能!

Guangzhou


使用全连接神经网络解决?

destination time of departure



循环神经网络

隐藏层输出存
储在记忆中




记忆内容可以用作
额外输入信息

循环神经网络

输入序列: $\begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix} \dots$

输出序列: $\begin{bmatrix} 4 \\ 4 \end{bmatrix}$




假设所有权重为“1”，没有偏置
且所有激活函数都为线性

循环神经网络

输入序列: $\begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix} \dots$

输出序列: $\begin{bmatrix} 4 \\ 4 \end{bmatrix} \begin{bmatrix} 12 \\ 12 \end{bmatrix}$



假设所有权重为“1”，没有偏置
且所有激活函数都为线性


循环神经网络

输入序列: $\begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix} \dots$


输出序列: $\begin{bmatrix} 4 \\ 4 \end{bmatrix} \begin{bmatrix} 12 \\ 12 \end{bmatrix} \begin{bmatrix} 32 \\ 32 \end{bmatrix}$

改变输入序列的顺序将会对输出产生影响!

Try the following sequence
With ReLU! $\begin{bmatrix} 2 \\ 2 \end{bmatrix} \begin{bmatrix} -1 \\ -1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \dots$



假设所有权重为“1”，没有偏置
且所有激活函数都为线性




循环神经网络

相同的网络结构多次使用

“arrive” 对应每个类别的概率

“Guangzhou” 对应每个类别的概率


“on” 对应每个类别的概率



循环神经网络


概率分布不同

“leave” 对应每个类别的概率




leave

“Guangzhou” 对应类别概率




Guangzhou

“arrive” 对应每个类别的概率



arrive

“Guangzhou” 对应类别概率



Guangzhou

记忆中存储的信息是不同的


循环神经网络训练

RNN forward pass

$$s_t = \tanh(Ux_t + Ws_{t-1})$$

$$\hat{y}_t = \text{softmax}(Vs_t)$$

$$E(y, \hat{y}) = -\sum_t E_t(y_t, \hat{y}_t)$$



循环神经网络训练

$$s_t = \tanh(Ux_t + Ws_{t-1})$$

$$\hat{y}_t = \text{softmax}(Vs_t)$$

Backpropagation Through Time (BPTT)

$$\frac{\partial E}{\partial W} = \sum_t \frac{\partial E_t}{\partial W}$$


$$\frac{\partial E_3}{\partial W} = \frac{\partial E_3}{\partial \hat{y}_3} \frac{\partial \hat{y}_3}{\partial s_3} \frac{\partial s_3}{\partial W}$$

But $s_3 = \tanh(Ux_t + Ws_2)$

s_3 depends on s_2 , which depends on W and s_1 , and so on.

$$\frac{\partial E_3}{\partial W} = \sum_{k=0}^3 \frac{\partial E_3}{\partial \hat{y}_3} \frac{\partial \hat{y}_3}{\partial s_3} \frac{\partial s_3}{\partial s_k} \frac{\partial s_k}{\partial W}$$

$$E(y, \hat{y}) = - \sum_t E_t(y_t, \hat{y}_t)$$



循环神经网络训练

The Vanishing Gradient Problem


$$\frac{\partial E_3}{\partial \mathbf{W}} = \sum_{k=0}^3 \frac{\partial E_3}{\partial \hat{y}_3} \frac{\partial \hat{y}_3}{\partial s_3} \frac{\partial s_3}{\partial s_k} \frac{\partial s_k}{\partial \mathbf{W}}$$

$$\frac{\partial E_3}{\partial \mathbf{W}} = \sum_{k=0}^3 \frac{\partial E_3}{\partial \hat{y}_3} \frac{\partial \hat{y}_3}{\partial s_3} \left(\prod_{j=k+1}^3 \frac{\partial s_j}{\partial s_{j-1}} \right) \frac{\partial s_k}{\partial \mathbf{W}}$$

Each partial is a Jacobian:


$$\frac{d\mathbf{f}}{d\mathbf{x}} = \begin{bmatrix} \frac{\partial \mathbf{f}}{\partial x_1} & \cdots & \frac{\partial \mathbf{f}}{\partial x_n} \end{bmatrix} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}$$

- Derivative of a vector w.r.t a vector is a matrix called Jacobian
- **激活函数的限制**: RNN 常用的激活函数 tanh 将输入映射到 (-1, 1) 之间, 而它的**导数最大值只有 1** (在输入为 0 时取得, 向两边快速衰减)。
- **矩阵范数受限**: 受激活函数导数大小和权重矩阵的影响, 上述雅可比矩阵的 2-范数 (2-norm) 通常有一个小于或等于 1 的上限。
- **指数级缩小**: 在长序列中, 由于反向传播需要经过**多次矩阵连乘**, 如果每次相乘的项都小于 1, 梯度值就会呈**指数级缩小** (shrink exponentially)。
- **结果**: 导致距离当前时刻较远的早期时间步 ("far away" steps) 传过来的梯度贡献变成 0, 网络无法学习到长距离的依赖关系。
- Depending on activation functions and network parameters, gradients could **explode** instead of vanishing




循环神经网络训练

当然，循环结构可以构造得很深 ...



长短期记忆网络


经典循环神经网络 (Recurrent Neural network)



回忆过去,痛苦的相思忘不了...
為何你還來 撥動我心跳...
緣難了 情難了...

长短期记忆网络 (Long Short-term Memory)


...你的影子無所不在...
落在过去, 飘向未来,...
就让往事随风都随风都随风,
心随你动...



Ref: 1. 萧敬腾, 《新不了情》, 2010
2. 齐秦, 《往事随风》, 1995

长短期记忆网络


长短期记忆网络 (Long Short-term Memory)



长短期记忆网络

通常使用 sigmoid 激活函数
限制在 0 到 1 之间
模拟门的开关

$$c' = g(z)f(z_i) + cf(z_f)$$



长短期记忆网络


LSTM 示例

	0	0	3	3	7	7	7	0	6
x_1	1	3	2	4	2	1	3	6	1
x_2	0	1	0	1	0	0	-1	1	0
x_3	0	0	0	0	0	1	0	0	1
y	0	0	0	0	0	7	0	0	6


当 $x_2 = 1$, 把 x_1 的值累加到记忆中

当 $x_2 = -1$, 重置记忆


当 $x_3 = 1$, 输出记忆的值





y 0 0 0 7 0





x_1	3	4	2	1	3
x_2	1	1	0	0	-1
x_3	0	0	0	1	0














网络结构


➤ 用 LSTM 替换原始神经元








学习目标




学习过程

Backpropagation through time (BPTT)




但是 ... 基于 RNN 的网络并不总是容易学习的

语言模型的真实案例



误差表面相当粗糙



误差表面经常相当平坦或者相当陡峭.

[Razvan Pascanu, ICML'13]

Why?

$$\begin{aligned} w = 1 & \Rightarrow y^{1000} = 1 \\ w = 1.01 & \Rightarrow y^{1000} \approx 20000 \end{aligned}$$

Large $\partial L / \partial w$


Small Learning rate?

$$\begin{aligned} w = 0.99 & \Rightarrow y^{1000} \approx 0 \\ w = 0.01 & \Rightarrow y^{1000} \approx 0 \end{aligned}$$


small $\partial L / \partial w$

Large Learning rate?

Toy Example



深度学习的可解释性



Local Explanation

为什么你认为 这张图片 是猫?

Global Explanation

你认为 "猫" 应该是什么样子?

深度学习的可解释性

为什么我们需要可解释的机器学习？



深度学习的可解释性

为什么我们需要可解释的机器学习？

用机器来协助判断简历

具体能力？还是性别？

用机器来协助判断犯人是否可以假释

具体证据？还是肤色？

金融相关的决策常常依法需要提供理由

为什么拒绝了某个人的贷款？


模型诊断：到底机器学到了什么

不能只看正确率？想想神马汉斯的故事

深度学习的可解释性

我们可以根据可解释性来改进机器学习模型

https://www.explainkcd.com/wiki/index.php/1838:_Machine_Learning



THIS IS YOUR MACHINE LEARNING SYSTEM?

YUP! YOU POUR THE DATA INTO THIS BIG PILE OF LINEAR ALGEBRA, THEN COLLECT THE ANSWERS ON THE OTHER SIDE.

WHAT IF THE ANSWERS ARE WRONG?

JUST STIR THE PILE UNTIL THEY START LOOKING RIGHT.

我知道答案为什么错，所以我可以修正它

With explainable ML

深度学习的可解释性

机器学习可解释性的目标 $\neq$ 完全清楚机器学习模型的工作机理

- 人脑也是一个黑盒模型!
- 人类不相信深度学习因为它是黑盒，但他们却相信其他人类的决策!

W

机器学习可解释性的目标是(个人观点)

- Make people (your customers, your boss, yourself) comfortable.
- Make machine controllable.

让人觉得“舒坦”

让机器变得“可控”

深度学习的可解释性

可解释性 v.s. 功能强大

- 某些模型本质上是可解释的
 - 例如，线性模型(可以从权重知道特征的重要性)
 - 但是，这种模型功能并不强大.
- 深度神经网络很难解释
 - 深度神经网络是黑盒


因为深度网络是黑盒，
所以我们不用它。

= 削足适履 ☹

- 但它功能远强大于线性模型 ...

Let's make deep network interpretable.

深度学习的可解释性




应该扩大“照明”范围，让强大的模型（钥匙）处于可解释（光照）范围内，而不是放弃使用照明范围外的物体。

Powerful Model

深度学习的可解释性

Local Explanation: Explain the Decision


Questions: Why do you think this image is a cat?



深度学习的可解释性

Basic Idea

Image: pixel, segment, etc.
Text: a word



Object x $\longrightarrow$ Components: $\{x_1, \dots, x_n, \dots, x_N\}$

我们想知道每个部分对于决策的重要程度

Idea: 移除或改变该部分的值，观察决策结果是否变化

决策变化较大 $\longrightarrow$ 该部分很重要


深度学习的可解释性

$$\{x_1, \dots, x_n, \dots, x_N\} \longrightarrow \{x_1, \dots, x_n + \Delta x, \dots, x_N\}$$

$$y_k \longrightarrow y_k + \Delta y$$

y_k : the prob of the predicted class of the model

$$\left| \frac{\Delta y}{\Delta x} \right| \longrightarrow \left| \frac{\partial y_k}{\partial x_n} \right|$$



特征图


深度学习的可解释性

Global Explanation: Explain the whole Model

Question: What do you think a “cat” looks like?

深度学习的可解释性


$$x^* = \arg \max_x y_i$$



Deep Neural Networks are Easily Fooled

<https://www.youtube.com/watch?v=M2lebCN9Ht4>

我们找出让卷积为最容易辨识的各个类别的输入
(给定输出类别, 卷积层最希望看到的输入)



深度学习的可解释性

Deep Neural Networks are Easily Fooled


High Prediction Scores for Unrecognizable Images

深度学习的可解释性


来自生成器 (Generator) 的限制

Training a generator

(by GAN, VAE, etc.)

Training
Examples

$$x^* = \arg \max_x y_i \Rightarrow z^* = \arg \max_z y_i \quad x^* = G(z^*)$$



深度学习的可解释性



redshank

ant

monastery



volcano

<https://arxiv.org/abs/1612.00005>

谢谢大家！

相关课程资源及参考文献请浏览

超算习堂: <https://easyhpc.net/course/143>